UNIVERSIDADE DE SÃO PAULO
Instituto de Ciências Matemáticas e de Computação

Tutorial para Modelagem e Análise de Séries Temporais

Aluno: José Fábio Viana de Brito
Curso: Estatística e Ciência de Dados
NUSP: 16300449

Orientador: Prof. Dr. Marinho G. Andrade Filho
Departamento: Matemática Aplicada e Estatística

São Carlos - SP
2025

UNIVERSIDADE DE SÃO PAULO

José Fábio Viana de Brito

Tutorial para Modelagem e Análise de Séries Temporais

Relatório final apresentado

Orientador: Prof. Dr. Marinho G. Andrade Filho

São Carlos - SP
2025

Sumário

1 Introdução **3**

2 Modelos Estruturais **5**
2.1 Modelo Estrutural Aditivo 5
2.2 Modelo Estrutural Multiplicativo 6

3 Transformação e Decomposição **7**
3.1 Transformação 7
3.2 Decomposição 8

4 Métodos de Suavização **10**
4.1 Médias Móveis Simples (MMS) 10
4.2 Suavização Exponencial Simples (SES) 12
4.3 Previsão com SES 12
4.4 Método de Holt (Tendência) 13
4.4.1 Formulação 13
4.4.2 Comparação com Regressão Linear 13
4.5 Método de Holt-Winters (Sazonalidade) 13
4.5.1 Modelo Aditivo 13
4.5.2 Modelo Multiplicativo 14
4.6 Aplicação Computacional no R 14
4.6.1 Exemplo SES 14
4.6.2 Exemplo Holt 15
4.6.3 Exemplo Holt-Winters 16

5 Modelos Autorregressivos e Médias Móveis **18**
5.1 Modelos Autorregressivos $AR(p)$ 18
5.2 Modelo de Média Móveis $MA(q)$ 19
5.3 Modelo $ARMA(p, q)$ 19
5.4 Modelo $ARIMA(p, d, q)$ 20
5.5 Modelo $SARIMA(p, d, q)(P, D, Q)_s$ 20

6 Estimação de modelos **22**
6.1 Verossimilhança 22
6.2 Critérios de Avaliação 22
6.3 Função de autocorrelação 23

7 Aplicações práticas **28**
7.1 Removendo tendências 28
7.2 Ajuste de modelos 29
7.3 Resíduos 32

8 Previsão **34**
8.1 Previsão com Modelos de Suavização Exponencial 34
8.1.1 Suavização Exponencial Simples (SES) 34
8.1.2 Método Linear de Holt 34
8.1.3 Método de Holt-Winters (Sazonal) 35
8.2 Previsão com Modelos ARIMA 35
8.2.1 A Equação de Diferenças 35
8.2.2 Exemplo Numérico: ARIMA(1,1,0) 36
8.2.3 Intervalos de Confiança 36
8.3 Implementação Prática 36

Capítulo 1

Introdução

Séries temporais são muito mais presentes do que acreditamos, podemos notar a presença dessa estrutura de dados constantemente. Quer seja através dos dados da inflação no Brasil, custos de sua empresa nos últimos meses, número ou volume de vendas de sua empresa nos últimos 5 anos. E assim segue por toda e qualquer área que se possa obter dados ao longo do tempo.

Sendo assim podemos começar primeiramente definindo o que vem a ser uma série temporal.

Definição 1.1 *Uma* ***série temporal*** *é uma realização de um processo estocástico discreto no tempo* $\{Y_t(\omega), t \in \mathbb{Z}, \omega \in \Omega\}$*, ou uma sequência ordenada de variáveis aleatórias indexadas temporalmente.*

Exemplo 1.1 *Seja* $\{X_n, n = 0, 1, 2, \cdots\}$*, uma coleção de variáveis aleatórias, tal que* X_n *é a quantidade de passageiros mensais em voos internacionais de uma companhia qualquer. Ver figura 1.1*

```
ts_AP<-AirPassengers
autoplot(ts_AP)+
    geom_line(linewidth = 0.9, color = 'blue')+
    labs(title = 'Número de passageiros internacionais')+
    xlab("Tempo")+
    ylab("Contagem")+
    theme_minimal()
```

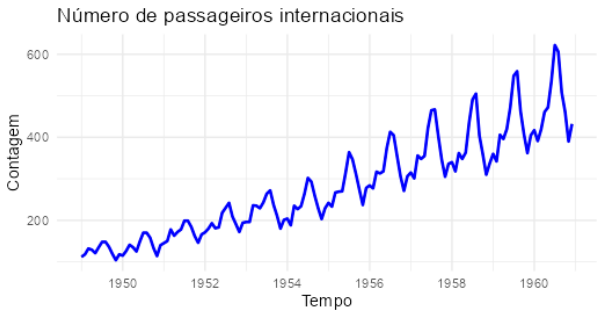


Figura 1.1: Número de passageiros em voos internacionais, 1949-1960

Os dados conforme vistos no gráfico é a série temporal X_n, obtida pela observação da realização das variáveis aleatórias mensalmente.

Este trabalho utilizará o software `R` para fazer as análises propostas, também ao longo do trabalho nos encarregaremos de mostrar como fazer cada um dos gráficos, dentro do texto ou no repositório do material, bem como, todas as análise e previsões. Para o resto do trabalho assumiremos que o leitor possui o devido conhecimento de todos os assuntos necessários para a total compreensão do assunto a ser estudado. Faremos apens a definição sem maiores discussões sobre os principais conceitos necessário para a compreensão do material.

- **Estacionariedade Forte (Estrita):** A distribuição conjunta de qualquer subconjunto de variáveis não depende do tempo. $(Y_{t_1}, \ldots, Y_{t_n}) \stackrel{d}{=} (Y_{t_1+h}, \ldots, Y_{t_n+h})$.
- **Estacionariedade Fraca (Segunda Ordem):** Exige apenas que a média seja constante ($\mathbb{E}[Y_t] = \mu$), a variância seja constante e finita ($Var(Y_t) = \sigma^2 < \infty$), e a covariância dependa apenas da defasagem h ($Cov(Y_t, Y_{t+h}) = \gamma(h)$).

Definição 1.2 (Ergodicidade e Teorema de Wold) *A propriedade de* ***ergodicidade*** *garante que as médias temporais de uma única realização convergem para os valores esperados teóricos do processo, permitindo inferir propriedades estatísticas a partir de uma única trajetória longa.*

O ***Teorema de Wold*** *estabelece que todo processo estacionário fraco (de média zero) pode ser decomposto como uma combinação linear infinita de inovações passadas (um processo $MA(\infty)$) mais um componente determinístico:*

$$Y_t = \mu_t + \sum_{j=0}^{\infty} \psi_j \epsilon_{t-j} \tag{1.1}$$

onde $\{\epsilon_t\}$ é um ruído branco e μ_t é puramente determinístico.

Isso justifica o uso de modelos ARMA/ARIMA como aproximações para processos estacionários.

Capítulo 2

Modelos Estruturais

A análise de séries temporais frequentemente utiliza modelos clássicos que decompõem os dados em características comuns e identificáveis. Os principais componentes considerados são:

- **Tendência (T_t):** representa uma mudança de longo prazo no nível médio da série.
- **Sazonalidade (S_t):** refere-se a padrões que se repetem em intervalos fixos de tempo.
- **Aleatoriedade ou Ruído (ϵ_t):** consiste nas variações imprevisíveis e não estruturadas.

Os modelos estruturais mais comumente utilizados para representar essas séries são o modelo aditivo e o modelo multiplicativo.

2.1 Modelo Estrutural Aditivo

No modelo aditivo, a série é decomposta como a soma de seus componentes:

$$y_t = T_t + S_t + \epsilon_t \tag{2.1}$$

Neste modelo, a sazonalidade possui amplitude constante ao longo do tempo. É adequado para séries onde as flutuações são estáveis, como a temperatura média mensal, onde as diferenças entre estações tendem a ser fixas.

Para vermos mais claramente tomemos a seguinte série:

Exemplo 2.1 *X_n, concentração de $CO2$ na atmosfera.*

```
ts_co<-co2
autoplot(ts_co)+
  geom_line(linewidth = 0.9, color = 'blue')+
  labs(title = 'Concentração atmosférica de CO2')+
  xlab("Tempo")+
  ylab("partes por milhão (ppm)")+
  theme_minimal()
```

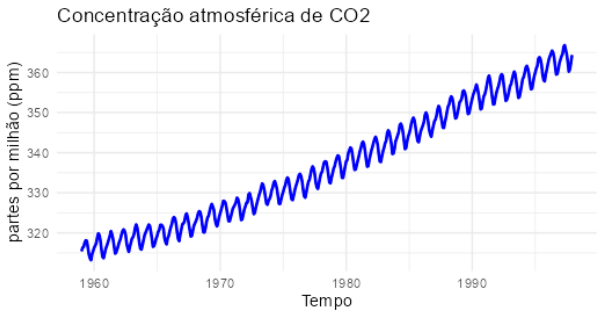


Figura 2.1: Concentração de CO2 na atmosfera, em partes por milhão

2.2 Modelo Estrutural Multiplicativo

No modelo multiplicativo, a série é representada como o produto dos componentes:

$$y_t = T_t \times S_t + \epsilon_t \tag{2.2}$$

Aqui, a sazonalidade é proporcional ao nível da série. Este modelo é indicado quando as flutuações crescem conforme a tendência aumenta, comportamento comum em séries de vendas em valor monetário. Podemos ver um exemplo de série temporal multiplicativa no exemplo 1.1

Tabela 2.1: Comparação entre Modelos Aditivo e Multiplicativo

Aspecto	**Aditivo**	**Multiplicativo**
Estrutura	$y_t = T_t + S_t + \epsilon_t$	$y_t = T_t \times S_t + \epsilon_t$
Sazonalidade	Constante	Proporcional ao nível
Adequado quando	Flutuações estáveis	Flutuações crescem com a série

Capítulo 3

Transformação e Decomposição

3.1 Transformação

Para melhor entendermos e conseguirmos modelar a série é preferível que tenhamos dados estacionários e com variância constante. Sendo assim, podemos aplicar transformações aos dados para obtermos melhores condições de trabalho. Neste trabalho abordaremos como aplicar a transformação de Box-Cox:

$$y_t = \begin{cases} (sign(x_t)|x_t|^{\lambda} - 1)/\lambda, & \lambda \neq 0 \\ \ln x_t, & \lambda = 0. \end{cases}$$

Como temos que fazer a seleção do parâmetro manualmente, utilizaremos o método de Guerrero para fazer a escolha do parâmetro λ de forma ótima. Podemos afirmar algo importante a cerca de λ, se o parâmetro for igual a 0, então o modelo é multiplicativo, e se for igual a 1, o modelo é aditivo. Para isso podemos usar as funções:

`BoxCox.lambda(x, method)`

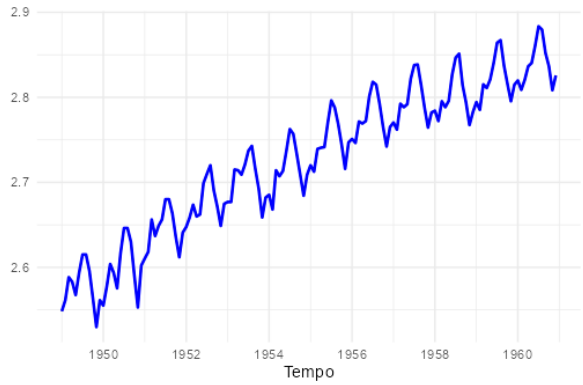
- `x`: Objeto da classe `ts`;
- `method`: Um método para a seleção do valor: `'guerrero'` ou `'logik'`.

`BoxCox(x,lambda)`

- `x`: Objeto da classe `ts`;
- `lambda`: Parâmetro da transformação.

Vejamos como aplicar e qual a utilidade prática de tais transformações, para isso utilizaremos o exemplo 1.1:

```
lambda_AP<-BoxCox.lambda(ts_AP, method = 'guerrero')
ts_AP_BC<-BoxCox(ts_AP,lambda_AP)
autoplot(ts_AP_BC)+
  geom_line(linewidth = 0.9, color = 'blue')+
  xlab("Tempo")+
  ylab("")+
  theme_minimal()
```



Note que agora, as variações sazonais são constantes ao longo de todo o período, tornando o processo com variância constante, ainda precisamos torná-lo estacionário, mas isso falaremos mais a frente.

3.2 Decomposição

Podemos, ainda, fazer a decomposição da série, ou seja, analisarmos cada um dos seus componentes: T_t, S_t, ϵ_t. No R podemos usar a função '`stl`', que faz a decomposição sazonal e têndencia usando Loess, uma regressão local. Faz-se útil esta decomposição para séries que podemos ter dúvida quanto à tendência da série.

```
stl(x, s.window,
    t.window = NULL,
    robust = FALSE)
```

- `x`: Objeto da classe `ts`;
- `s.window`: `"periodic"`força a função a tratar a sazonalidade igual em todo período observado. Quando não colocamos `"periodic"`, devemos por um número inteiro impar maior, ou igual a 7, que representa a rigidez da mudança da sazonalidade;
- `t.window`: o valor padrão é *NULL,* em que a função calcula um valor de suavidade na linha da tendência baseado na sazonalidade. Quando não usado o valor padrão, devemos por um número inteiro impar, quanto maior o número maior a suavidade;
- `robust`: `TRUE` ou `FALSE`, quando colocamos `TRUE` a decomposição se torna resistente a outliers.

Utilizando ainda os dados dos exemplos 1.1, e 2.1, façamos a decomposição:

- Modelo Aditivo:

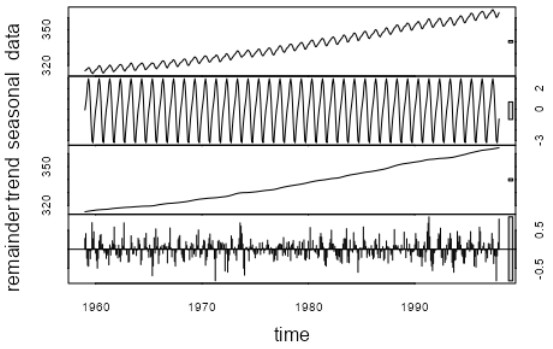


Figura 3.1: Decomposição da série temporal `CO2`

- Modelo Multiplicativo:

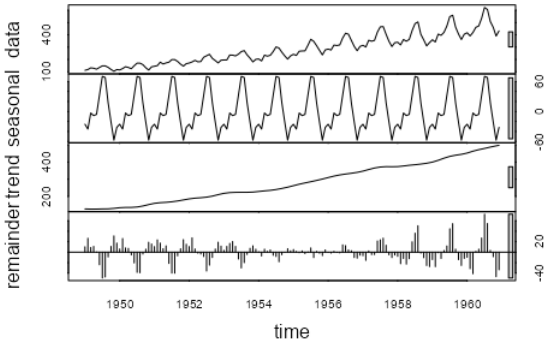


Figura 3.2: Decomposição da série temporal `AP`

Note que para a decomposição 3.2 parece normal, entretanto olhando para a ultima linha vemos que o componente ϵ_t não possui um comportamento aleatório, mais um ponto a favor da série ser multiplicativa. Ao contrário da decomposição 3.1 que o componente ϵ_t apresenta comportamento aleatório e com média 0.

Capítulo 4

Métodos de Suavização

Os métodos de suavização são técnicas fundamentais na análise exploratória e na previsão de curto prazo. Eles são utilizados para identificar e estimar a tendência e a sazonalidade ao remover as flutuações aleatórias (ruído).

Considera-se, inicialmente, um modelo para uma série temporal localmente constante, definida por $y_t = \mu_t + \epsilon_t$, onde μ_t é o nível da série (geralmente constante ou variando suavemente) e ϵ_t é um ruído aleatório com $E(\epsilon_t) = 0$ e $Var(\epsilon_t) = \sigma_\epsilon^2$. O objetivo da suavização é destacar o nível μ_t.

4.1 Médias Móveis Simples (MMS)

A média móvel de ordem r é calculada pela média dos valores recentes. É uma estimativa $\hat{y}_t$ do nível μ_t:

$$\hat{y}_t = \frac{y_t + y_{t-1} + \cdots + y_{t-r+1}}{r} \tag{4.1}$$

Alternativamente, pode ser atualizada recursivamente:

$$\hat{y}_t = \hat{y}_{t-1} + \frac{y_t - y_{t-r}}{r} \tag{4.2}$$

Vejamos como fazer com os dados do exemplo 1.1:

```
ts_AP_MAC5<-ma(ts_AP,order = 5, centre = TRUE)
ts_AP_MAC12<-ma(ts_AP,order = 12, centre = TRUE)
ts_AP_MANC5<- ma(ts_AP, order = 5, centre = FALSE)
ts_AP_MANC12<- ma(ts_AP, order = 12, centre = FALSE
#Gráfico das médias moveis centrais
plot_APMAC <- autoplot(ts_AP, series = "Passageiros") +
  autolayer(ts_AP_MAC5, series = "Média Móvel central 5") +
  autolayer(ts_AP_MAC12, series = "Média Móvel central 12") +
  labs(
    x = "Tempo",
    y = "Contagem (x1.000)",
    color = "Legenda"
  ) +
  scale_color_manual(
    values = c("Passageiros" = "gray",
```

```
              "Média Móvel central 5" = "red",
              "Média Móvel central 12" = "yellow")
  ) +
  theme_minimal()+
  theme(
    legend.position = "inside",
    legend.position.inside = c(0.02, 0.95),
    legend.justification = c(0, 1),
    legend.background = element_rect(
    fill = alpha("white", 0.8),
    color = "gray50"),
    legend.title = element_text(face = "bold")
  )
```

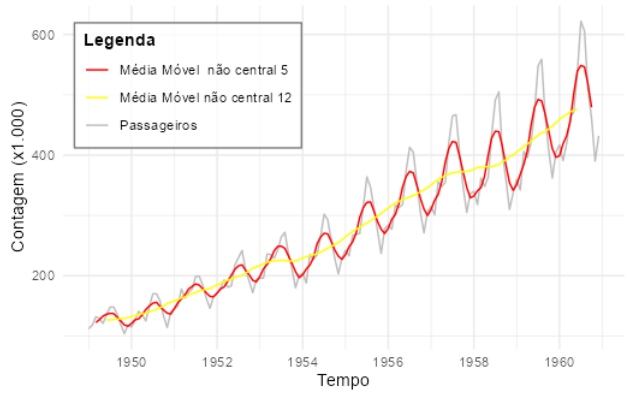


Figura 4.1: Média móvel de ordem 5 e ordem 12

A previsão para todos os valores futuros ($h > 0$) é dada pela última média móvel calculada: $\hat{y}_t(h) = \hat{y}_t$.

Mais comumente realizamos a suavização por média móvel centrada em y_t. Sendo assim, a média móvel de ordem q centrada em y_t, é dada por:

- Caso par ($q = 2k$):

$$\hat{y}_t = \frac{1}{k}\left[\frac{1}{2}y_{t-k} + y_{t-(k-1)} + \cdots + y_{t+(m-1)} + \frac{1}{2}y_{t+m}\right]$$

- Caso impar($q = 2k + 1$):

$$\hat{y}_t = \frac{1}{k}\sum_{i=-k}^{+k} y_{t+i}$$

Vejamos com os dados do exemplo 2.1:

```
ts_co<-co2
ts_co_MAC5<-ma(ts_co,order = 5, centre = TRUE)
ts_co_MAC12<-ma(ts_co,order = 12, centre = TRUE)
ts_co_MANC5<- ma(ts_co, order = 5, centre = FALSE)
```

```
ts_co_MANC12<- ma(ts_co, order = 12, centre = FALSE)
plot_coMANC <- autoplot(ts_co, series = "Concentração") +
  autolayer(ts_co_MANC5, series = "Média Móvel  não central 5") +
  autolayer(ts_co_MANC12, series = "Média Móvel não central 12") +
  labs(
    x = "Tempo",
    y = "partes por milhão (ppm)",
    color = "Legenda"
  ) +
  scale_color_manual(
    values = c("Concentração" = "gray",
               "Média Móvel  não central 5" = "red",
               "Média Móvel não central 12" = "yellow")
  ) +
  theme_minimal()+
  theme(
    legend.position = "inside",
    legend.position.inside = c(0.02, 0.95),
    legend.justification = c(0, 1),
    legend.background = element_rect(
    fill = alpha("white", 0.8),
    color = "gray50"),
    legend.title = element_text(face = "bold")
  )
```

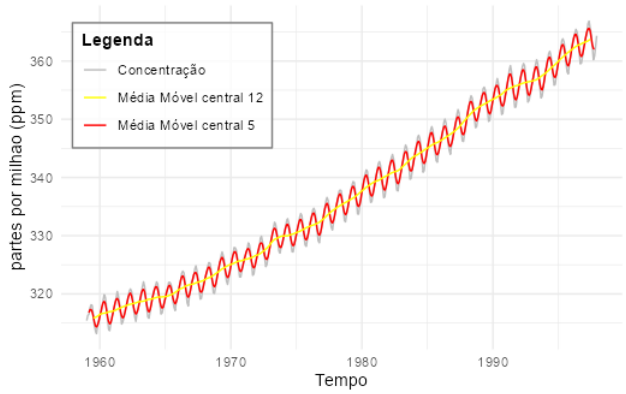


Figura 4.2: Média Móvel Central de ordem 5 e ordem 12

4.2 Suavização Exponencial Simples (SES)

A Suavização Exponencial Simples (SES) é indicada para séries temporais que apresentam comportamento relativamente estável, sem tendência ou sazonalidade marcantes. O objetivo é suavizar a série dando mais peso às observações mais recentes.

A estimativa suavizada no tempo t é dada por:

$$\hat{y}_t = \alpha y_t + (1-\alpha)\hat{y}_{t-1}, \quad \text{para } t = 1, 2, \ldots, n \tag{4.3}$$

onde $\alpha \in [0, 1]$ é o parâmetro de suavização. A inicialização usual é $\hat{y}_0 = y_1$ (ou similar).

Podemos expandir esta equação para ver que $\hat{y}_t$ é uma soma ponderada de todas as observações passadas, com pesos decrescendo exponencialmente:

$$\hat{y}_t = \alpha \sum_{k=0}^{t-1} (1-\alpha)^k y_{t-k} + (1-\alpha)^t \hat{y}_0 \tag{4.4}$$

4.3 Previsão com SES

A previsão para qualquer horizonte $h > 0$ é plana, igual ao último valor suavizado:

$$\hat{y}_t(h) = \hat{y}_t \tag{4.5}$$

A forma de correção de erros para previsão um passo à frente é $\hat{y}_t(1) = \alpha e_t + \hat{y}_{t-1}(1)$, onde e_t é o erro de previsão.

4.4 Método de Holt (Tendência)

O Método de Holt é uma extensão da SES que permite capturar séries com nível e tendência linear. Ele utiliza dois componentes que são atualizados recursivamente: o nível (l_t) e a tendência (b_t).

4.4.1 Formulação

As equações de atualização são:

$$l_t = \alpha y_t + (1-\alpha)(l_{t-1} + b_{t-1}) \tag{4.6}$$
$$b_t = \beta(l_t - l_{t-1}) + (1-\beta) b_{t-1} \tag{4.7}$$

Onde α controla a suavização do nível e β controla a suavização da tendência.

A previsão para h passos à frente é dada por:

$$\hat{y}_t(h) = l_t + h \cdot b_t \tag{4.8}$$

4.4.2 Comparação com Regressão Linear

Embora tanto o método de Holt quanto a regressão linear possam modelar tendências, eles têm propósitos distintos:

- **Método de Holt:** É recursivo e adaptativo. Ideal para previsões em tempo real, pois dá mais peso às observações recentes e se adapta rapidamente a mudanças na tendência. Não requer hipóteses fortes sobre os resíduos.
- **Regressão Linear:** Ajusta uma tendência global fixa. É melhor para inferência, explicação da taxa média de crescimento histórica ou quando se deseja incorporar variáveis explicativas externas.

4.5 Método de Holt-Winters (Sazonalidade)

O método de Holt-Winters estende o método de Holt para capturar também a sazonalidade. Ele decompõe a série em três partes: Nível (l_t), Tendência (b_t) e Sazonalidade (s_t), com período m.

4.5.1 Modelo Aditivo

Usado quando a amplitude da sazonalidade é constante.

$$l_t = \alpha(y_t - s_{t-m}) + (1-\alpha)(l_{t-1} + b_{t-1}) \tag{4.9}$$
$$b_t = \beta(l_t - l_{t-1}) + (1-\beta)b_{t-1} \tag{4.10}$$
$$s_t = \gamma(y_t - l_t) + (1-\gamma)s_{t-m} \tag{4.11}$$

Previsão h passos à frente:

$$\hat{y}_t(h) = l_t + hb_t + s_{t+h-mk}, \quad \text{onde } k = \lfloor \frac{h-1}{m} \rfloor \tag{4.12}$$

4.5.2 Modelo Multiplicativo

Usado quando a amplitude da sazonalidade varia proporcionalmente ao nível da série.

$$l_t = \alpha\frac{y_t}{s_{t-m}} + (1-\alpha)(l_{t-1} + b_{t-1}) \tag{4.13}$$
$$b_t = \beta(l_t - l_{t-1}) + (1-\beta)b_{t-1} \tag{4.14}$$
$$s_t = \gamma\frac{y_t}{l_t} + (1-\gamma)s_{t-m} \tag{4.15}$$

Previsão h passos à frente:

$$\hat{y}_{t+h} = (l_t + hb_t) \times s_{t+h-mk} \tag{4.16}$$

Os parâmetros α, β, γ controlam, respectivamente, a suavização do nível, da tendência e da sazonalidade.

4.6 Aplicação Computacional no R

No ambiente R, a função principal para estes métodos é a 'HoltWinters'.

```
HoltWinters(x, alpha = NULL, beta = NULL, gamma = NULL,
            seasonal = c("additive", "multiplicative"),
            start.periods = 2,
            optim.start = c(alpha = 0.3,
                            beta = 0.1,
                            gamma = 0.1),
            ...)
```

- `x`: Objeto da classe `ts` (série temporal).

- `alpha, beta, gamma`: Parâmetros de suavização. Se `NULL`, são estimados automaticamente.
- `beta=FALSE`: Realiza apenas Suavização Exponencial Simples.
- `gamma=FALSE`: Realiza o método de Holt (sem sazonalidade).

Faremos exemplos para cada um dos tipos de suavização exponencial:

4.6.1 Exemplo SES

Utilizaremos os dados `Nile`, que é o fluxo anual do Rio Nilo.

```
fit_SES<-HoltWinters(Nile, beta= FALSE, gamma = FALSE)
pred_SES<- predict(fit_SES, n.ahead = 10)
plot_Nile <- autoplot(Nile, series = "Original") +
  autolayer(fitted(fit_SES)[, "xhat"], series = "Suavização Exponencial") +
  autolayer(pred_SES, series = "Previsão com SES")
  labs(
    x = "Tempo",
    y = "Fluxo (x100hm³)",
    color = "Legenda"
  ) +
  scale_color_manual(
    values = c("Original" = "gray",
               "Suavização Exponencial" = "red",
               "Previsão com SES = "orange")
  ) +
  theme_minimal() +
  theme(
    legend.position = "inside",
    legend.position.inside = c(0.62, 0.95),
    legend.justification = c(0, 1),
    legend.background = element_rect(
                        fill = alpha("white", 0.8),
                        color = "gray50"),
    legend.title = element_text(face = "bold")
  )
```

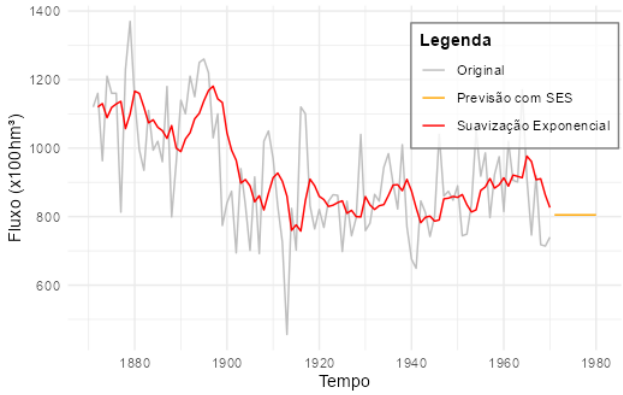


Figura 4.3: Suavização Exponencial Simples do *dataset Nile*

4.6.2 Exemplo Holt

Faremos a suavização de Holt com os dados do conjunto `uspop`, da população dos Estados Unidos da América.

```
fit_Holt<-HoltWinters(uspop,gamma = FALSE)
pred_Holt<- predict(fit_Holt, n.ahead = 5)
plot_Holt<- autoplot(uspop, series = "Original") +
  autolayer(fitted(fit_Holt)[, "xhat"], series = "Suavização de Holt") +
  autolayer(pred_Holt, series = "Previsão com Holt")+
  labs(
    x = "Tempo",
    y = "População (1M)",
    color = "Legenda"
  ) +
  scale_color_manual(
    values = c("Original" = "gray",
               "Suavização de Holt" = "red",
               "Previsão com Holt" = "orange")
  ) +
  theme_minimal() +
  theme(
    legend.position = "inside",
    legend.position.inside = c(0.02, 0.95),
    legend.justification = c(0, 1),
    legend.background = element_rect(fill =
                        alpha("white", 0.8),
                        color = "gray50"),
    legend.title = element_text(face = "bold")
  )
```

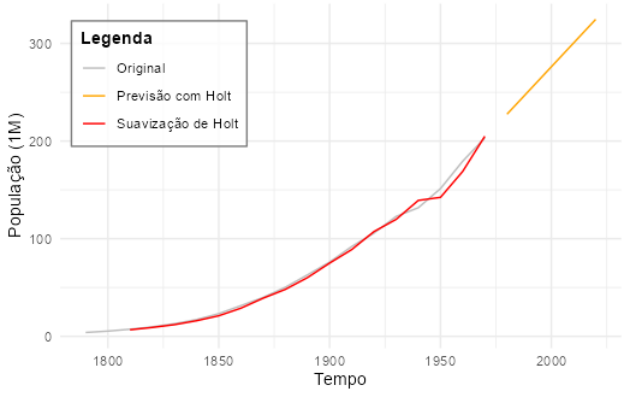


Figura 4.4: Suavização de Holt do *dataset uspop*

4.6.3 Exemplo Holt-Winters

Para vermos um exemplo de Holt-Winters utilizaremos os dados do exemplo 1.1, pois a série possui tendência e sazonalidade. Precisamos notar nesse modelo de suavização que devemos contar com o modelo de estrutura da série e nesse caso é multiplicativa.

```
fit_HW<-HoltWinters(AirPassengers, seasonal = 'multiplicative')
pred_HW<-predict(fit_HW, n.ahead = 10)
plot_HW<- autoplot(AirPassengers, series = "Original") +
  autolayer(fitted(fit_HW)[, "xhat"], series = "Suavização de Holt-Winters") +
  autolayer(pred_HW, series = "Previsão com Holt-Winters")+
  labs(
    x = "Tempo",
    y = "Contagem (x1.000)",
    color = "Legenda"
  ) +
  scale_color_manual(
    values = c("Original" = "gray",
               "Suavização de Holt-Winters" = "red",
               "Previsão com Holt-Winters" = 'orange')
  ) +
  theme_minimal() +
  theme(
    legend.position = "inside",
    legend.position.inside = c(0.02, 0.95),
    legend.justification = c(0, 1),
    legend.background = element_rect(fill =
                        alpha("white", 0.8),
                        color = "gray50"),
    legend.title = element_text(face = "bold")
  )
```

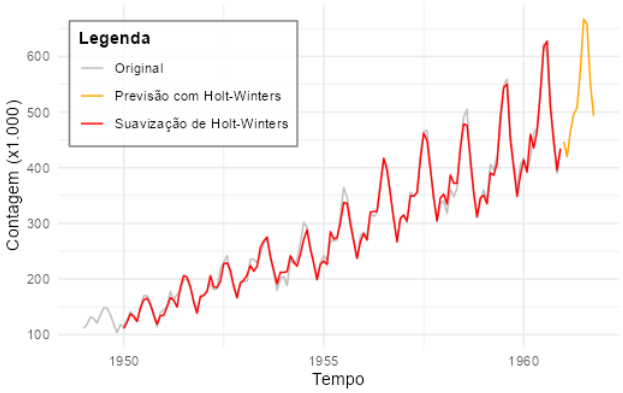


Figura 4.5: Suavização de Holt-Winters

Capítulo 5

Modelos Autorregressivos e Médias Móveis

Os modelos autorregressivos e de médias móveis formam uma das principais classes de modelos utilizados na análise e previsão de séries temporais. Eles permitem capturar as dependências lineares entre observações ao longo do tempo, sendo amplamente aplicados em economia, engenharia, finanças e ciências ambientais.

5.1 Modelos Autorregressivos $AR(p)$

Uma série autorregressiva expressam o valor atual como uma função linear dos valores passados, mais especificamente: se X_t for uma série autorregressiva de ordem p, $AR(p)$, então ela expressa o valor atual da série como uma função linear dos últimos p valores. Sua forma é dada por:

$$X_t = \phi_1 X_{t-1} + \phi_2 X_{t-2} + \cdots + \phi_p X_{t-p} + \varepsilon_t \tag{5.1}$$

onde:

- X_t: valor da série no tempo t;
- $\phi_1, \phi_2, \ldots, \phi_p$: parâmetros autorregressivos;
- ε_t: ruído branco com média zero e variância constante σ^2.

Definindo B, tal que: $BX_t = X_{t-1}$, temos:

$$\phi(B)X_t = \varepsilon_t, \tag{5.2}$$

com

$$\phi(B) = 1 - \phi_1 B - \phi_2 B^2 - \cdots - \phi_p B^p.$$

Parte importante desse modelo é a estacionariedade. Sendo assim podemos dizer que o modelo $AR(p)$ é estacionário se as raízes do polinômio $\phi(B) = 0$ estiverem fora do circulo unitário, mais precisamente, se o módulo das raízes forem maiores que 1.

Podemos entender o modelo como uma série em que os valores de um passado recente influenciam o presente. No caso particular de $p = 1$:

$$X_t = \phi_1 X_{t-1} + \varepsilon_t, \tag{5.3}$$

- se $\phi_1 > 0$: a série apresenta **inércia positiva** (valores tendem a seguir a mesma direção);
- se $\phi_1 < 0$: há **reversão de sinal** (valores tendem a oscilar).

5.2 Modelo de Média Móveis $MA(q)$

Um modelo $MA(q)$, são séries que podem ser modeladas por um processo de médias móveis, descrevem o valor atual da série como uma série de choques aleatórios passados. Se uma série, X_t, segue um modelo de médias moveis de ordem q, $MA(q)$, então podemos descrever como:

$$X_t = \varepsilon_t + \theta_1\varepsilon_{t-1} + \theta_2\varepsilon_{t-2} + \cdots + \theta_q\varepsilon_{t-q}, \tag{5.4}$$

onde:

- ε_t: ruído branco com média zero e variância σ^2;
- $\theta_1, \theta_2, \ldots, \theta_q$: parâmetros de médias móveis.

Em notação de operador de defasagem:

$$X_t = \theta(B)\varepsilon_t, \tag{5.5}$$

com

$$\theta(B) = 1 + \theta_1 B + \theta_2 B^2 + \cdots + \theta_q B^q.$$

O modelo MA(q) é invertível se as raízes do polinômio $\theta(B) = 0$ estiverem fora do círculo unitário. Essa condição garante que o modelo possa ser representado como um processo autorregressivo infinito (AR(∞)) e que sua forma seja única.

Podemos interpretar o modelo $MA(q)$ como o efeito de choques aleatórios temporários. Por exemplo para $q = 1$:

$$X_t = \varepsilon_t + \theta_1\varepsilon_{t-1}. \tag{5.6}$$

O valor atual depende do erro presente e de um erro anterior — uma memória curta de um passo.

Tabela 5.1: Comparação entre os modelos AR(p) e MA(q)

Característica	**AR(p)**	**MA(q)**
Dependência	Dos valores passados da série	Dos erros passados
Condição fundamental	Estacionariedade	Invertibilidade
Memória	Longa (efeito decai gradualmente)	Curta (efeito limitado a q períodos)
Representação alternativa	AR(p) $\rightarrow$ MA(∞)	MA(q) $\rightarrow$ AR(∞)
Exemplo típico	Séries econômicas com tendência persistente	Séries com choques temporários

5.3 Modelo $ARMA(p, q)$

O modelo **ARMA (AutoRegressive Moving Average)** combina duas componentes:

- uma **parte autorregressiva (AR)**, que explica o valor atual da série como uma combinação linear de valores passados;

- uma **parte de médias móveis (MA)**, que incorpora o efeito de choques aleatórios passados (ruídos) sobre o valor presente.

A forma geral do modelo ARMA(p, q) é:

$$X_t = \phi_1 X_{t-1} + \phi_2 X_{t-2} + \cdots + \phi_p X_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q} \tag{5.7}$$

Usando o operador de defasagem B (onde $BX_t = X_{t-1}$), tem-se:

$$\phi(B) X_t = \theta(B) \varepsilon_t \tag{5.8}$$

onde:

$$\phi(B) = 1 - \phi_1 B - \cdots - \phi_p B^p, \quad \theta(B) = 1 + \theta_1 B + \cdots + \theta_q B^q$$

O termo ε_t representa um ruído branco com média zero e variância constante σ^2. O modelo ARMA é apropriado para séries **estacionárias**, isto é, com média, variância e covariância constantes ao longo do tempo.

5.4 Modelo $ARIMA(p, d, q)$

Muitas séries temporais reais não são estacionárias — exibem tendência ou variações de nível. O modelo **ARIMA (AutoRegressive Integrated Moving Average)** estende o ARMA ao incluir a diferenciação para tratar a não estacionariedade.

A série original X_t é diferenciada d vezes:

$$\nabla^d X_t = (1 - B)^d X_t \tag{5.9}$$

O modelo ARIMA(p, d, q) é então definido por:

$$\phi(B)(1 - B)^d X_t = \theta(B) \varepsilon_t \tag{5.10}$$

Assim, após diferenciar a série d vezes, o resultado segue um modelo ARMA(p, q).

Os parâmetros têm a seguinte interpretação:

- p: número de termos autorregressivos;
- d: número de diferenciações aplicadas;
- q: número de termos de médias móveis.

Modelos ARIMA são amplamente utilizados em previsão de séries com tendência, como PIB, vendas e inflação.

5.5 Modelo $SARIMA(p, d, q)(P, D, Q)_s$

O modelo **SARIMA (Seasonal ARIMA)** ou **ARIMA sazonal** amplia o ARIMA para lidar com padrões sazonais, ou seja, repetições cíclicas em intervalos regulares (mensais, trimestrais, anuais).

A formulação geral é:

$$\phi(B)\Phi(B^s)(1 - B)^d (1 - B^s)^D X_t = \theta(B)\Theta(B^s)\varepsilon_t \tag{5.11}$$

onde:

- s: período da sazonalidade (por exemplo, $s = 12$ para dados mensais com padrão anual);
- $\Phi(B^s) = 1 - \Phi_1 B^s - \cdots - \Phi_P B^{Ps}$: componente autorregressiva sazonal;
- $\Theta(B^s) = 1 + \Theta_1 B^s + \cdots + \Theta_Q B^{Qs}$: componente de médias móveis sazonais;
- D: ordem de diferenciação sazonal.

O modelo combina:

- **p, d, q**: componentes não sazonais;
- **P, D, Q, s**: componentes sazonais.

É indicado para séries com padrões periódicos, como consumo de energia, turismo ou temperatura média mensal.

Tabela 5.2: Comparação entre modelos ARMA, ARIMA e SARIMA

Modelo	**Estacionariedade**	**Sazonalidade**	**Diferença aplicada**	**Exemplo de uso**
ARMA(p, q)	Sim	Não	Nenhuma	Retornos financeiros
ARIMA(p, d, q)	Não (torna-se após dif.)	Não	Sim	PIB, vendas
SARIMA(p, d, q)(P, D, Q)$_s$	Não (com dif. sazonal)	Sim	Sim e sazonal	Consumo mensal, turismo

Capítulo 6

Estimação de modelos

6.1 Verossimilhança

Como vimos no último capítulo podemos notar que os modelos apresentados dependem de parâmetros únicos de descrição do modelo. Para fazermos a seleção do modelo correto para melhor descrever os dados que possuímos devemos ter muita atenção na escolha desses ditos parâmetros. Podemos fazer isso através de métodos de inferência, mas que pela sua complexidade de resolução analítica utilizaremos de recursos computacionais. Uma ferramenta útil para os trabalhos de ajuste e seleção dos modelos é a função de verossimilhança. Vejamos como fazer a função de alguns dos modelos visto no capítulo anterior:

Exemplo 6.1 *Para um modelo $ARIMA(p,d,q)$, e média $\mu = 0$ temos o vetor dos parâmetros dados por:*

$$\boldsymbol{\xi} = (\boldsymbol{\phi}, \boldsymbol{\theta}, \sigma^2),$$

em que: $\boldsymbol{\phi} = (\phi_1, \cdots, \phi_p)$, $\boldsymbol{\theta} = (\theta_1, \cdots, \theta_q)$, e para fins de notação: $\boldsymbol{\eta} = (\boldsymbol{\phi}, \boldsymbol{\theta})$. Aqui assumiremos que $\varepsilon_t \overset{iid}{\sim} N(0, \sigma^2)$.

Dadas N observações do modelo, tomemos $\tilde{X}_t = \Delta^d X_t$, e assim temos $n = N - d$ observações úteis.Podemos reescrever o modelo em função do último erro ε_t. Sendo assim, ficamos com:

$$\varepsilon_t = \tilde{X}_t - \sum_{j=1}^{p} \phi_j \tilde{X}_{t-j} + \sum_{k=1}^{q} \theta_k \varepsilon_{t-k}.$$

Aqui se faz fundamental que tenhamos pelo menos peq observações de X_t e ε_t, respectivamente.

Dessa maneira, por conseguinte da distribuição de ε_t, podemos obter que:

$$\begin{aligned} L(\boldsymbol{\xi}|\boldsymbol{X}) &= \prod_{t=1}^{n} f(\varepsilon_t) \\ &= \frac{1}{\sqrt{2\pi\sigma^2}} exp\left\{ -\frac{1}{2\sigma^2} \sum_{t=1}^{n} (\tilde{X}_t - \sum_{j=1}^{p} \phi_j \tilde{X}_{t-j} + \sum_{k=1}^{q} \theta_k \varepsilon_{t-k})^2 \right\}. \end{aligned}$$

19 Portanto, obtemos:

$$\ell(\boldsymbol{\xi}) = -n \log \sigma^2 - \frac{S(\boldsymbol{\eta}|\boldsymbol{W})}{2\sigma^2}.$$

6.2 Critérios de Avaliação

Quando fazemos a organização e visualização dos dados começamos a pensar em qual modelo encaixar para cada série que estamos analisando. Sendo assim, temos que estabelecer

critérios de seleção de modelos para a série analisada. Os mais populares e recomendados pela literatura corrente são os critérios: AIC, Critério de Informação de Akaike; AICC, Critério de informação de Akaike corrigido; BIC, Crtiério de informação bayesiano.

Seja n o número de observações efetivas que é equivalente ao numero de resíduos na série, ou seja, se diferenciarmos um modelo não estacionário d vezes então temos $n = N - d$, em que N é o numero total de observações. Sendo assim, temos então:

$$\begin{aligned} \text{AIC} &= -2\ell(\cdot) + 2r \\ &\approx n\ln(\hat{\sigma}_a^2) + 2r \end{aligned}$$

Em que:

- $\ell(\cdot)$ é a função de verossimilhança dos parâmetros do modelo escolhido;
- r é o número de parâmetros do modelo;
- $\hat{\sigma}_a^2$ é a variância dos resíduos do modelo escolhido.

O Critério de Informação de Akaike funciona avaliando a variância dos resíduos do ajuste do modelo de explicação da série temporal, mas penaliza o número de parâmetros de cada modelo. Ou seja, se temos um ajuste bom mas com alto número de parâmetros, certamente o AIC será penalizado.

O AIC corrigido é definido por:

$$\begin{aligned} \text{AICc} &= -2\ell(\cdot) + \tfrac{2rn}{n-r-1} \\ &\approx n\ln(\hat{\sigma}_a^2) + \tfrac{2rn}{n-r-1} \end{aligned}$$

Em alguns casos, o AIC consegue fazer uma superestimação do parâmetro, faz-se então uma maior penalização do número de parâmetros a fim de corrigir o viés da estimação.

Por último, temos o BIC:

$$\begin{aligned} \text{BIC} &= -2\ell(\cdot) + r\,ln(n) \\ &\approx n\ln(\hat{\sigma}_a^2) + r\,ln(n) \end{aligned}$$

Semelhante aos outros, também faz uma penalização para o número r de parâmetros, nesse caso faz-se uma penalidade mais dura forçando que o modelo tenha o menor número de parâmetros.

Para melhor conseguirmos identificar modelos e comportamentos das séries podemos utilizar de uma ferramenta muito poderosa o **correlograma**. Semelhante a análise exploratória de dados para correlação linear, nesse caso olharemos para a correlação de valores dentro da série.

6.3 Função de autocorrelação

A ferramenta de principal utilidade na análise de dados para avaliar a correlação é a covariância e correlação entre duas variáveis diferentes, como estamos trabalhando com apenas 1 fazemos uma forma de "separação"em 2 séries em função do "atraso"entre as observações.

Definição 6.1 *Seja X_t uma série temporal estacionária, então a Função de Autocovariância é dada por:*

$$\gamma_k = E[X_{t+k}X_t]$$

Estimamos como:

$$\hat{\gamma}_k = \frac{1}{N}\sum_{t=1}^{T-k}(x_{t+k} - \bar{x})(x_{t-k} - \bar{z})$$

Em que N é o número de observações. Ainda com base em dados de conjuntos diferentes conseguimos fazer a extensão para uma única série temporal:

Definição 6.2 *A Função de autocorrelação (ACF) é dada por:*

$$\rho_k = \frac{\gamma_k}{\gamma_0},$$

em que $\gamma(0)$, é a variância da série. E estimamos através da fórmula:

$$\hat{\rho}_k = r_k = \frac{\sum_{t=k+1}^{T}(x_t - \bar{x})(x_{t-k} - \bar{x})}{\sum_{t=1}^{T}(x_t - \bar{x})^2},$$

Exemplo 6.2 *Seja X_t é um processo $AR(1)$. Logo:*

$$X_t = \phi X_{t-1} + \varepsilon_t, \quad |\phi| < 1$$

Para encontrar a ACF, primeiro determinamos a autocovariância de defasagem k, denotada por $\gamma_k = E[X_tX_{t-k}]$. Multiplicando a equação do modelo por X_{t-k} e tomando a esperança:

$$E[X_tX_{t-k}] = E[\phi X_{t-1}X_{t-k} + \varepsilon_t X_{t-k}]$$

Como a_t é independente de observações passadas ($\varepsilon_t \overset{iid}{\sim} WN(0, \sigma^2)$), temos para $k > 0$:

$$\gamma_k = \phi\gamma_{k-1}$$

A Função de Autocorrelação ρ_k é definida como $\frac{\gamma_k}{\gamma_0}$. Dividindo ambos os lados por γ_0:

$$\frac{\gamma_k}{\gamma_0} = \phi\frac{\gamma_{k-1}}{\gamma_0} \implies \rho_k = \phi\rho_{k-1}$$

Como $\rho_0 = 1$ por definição, a solução por recorrência é dada por:

$$\rho_k = \phi^k, \quad k \geq 0$$

O vetor das primeiras k autocorrelações pode ser escrito como:

$$\boldsymbol{\rho} = \left(\phi, \phi^2, \ldots, \phi^k\right).$$

Podemos notar que através do desenvolvimento que a autocorrelação de um processo $AR(p)$ tende a ter um decaimento exponencial nos valores. Vejamos o comportamento de um processo $MA(1)$.

Exemplo 6.3 *Seja X_t um processo $MA(1)$. Logo:*

$$X_t = \varepsilon_t + \theta\varepsilon_{t-1}$$

Para encontrar a ACF, primeiro determinamos a autocovariância de defasagem k, denotada por $\gamma_k = E[X_t X_{t-k}]$. Substituindo a equação do modelo e tomando a esperança para $k = 0$:

$$E[X_t X_t] = E[(\varepsilon_t + \theta\varepsilon_{t-1})^2]$$

Como ε_t é independente de observações passadas ($\varepsilon_t \overset{iid}{\sim} WN(0, \sigma^2)$), temos para $k = 0$:

$$\gamma_0 = \sigma^2(1 + \theta^2)$$

Para $k = 1$, multiplicamos a equação por X_{t-1} e tomamos a esperança:

$$E[X_t X_{t-1}] = E[(\varepsilon_t + \theta\varepsilon_{t-1})(\varepsilon_{t-1} + \theta\varepsilon_{t-2})] = \theta E[\varepsilon_{t-1}^2]$$

$$\gamma_1 = \theta\sigma^2$$

Para $k > 1$, os termos não se sobrepõem no tempo, resultando em:

$$\gamma_k = 0$$

A Função de Autocorrelação ρ_k é definida como $\frac{\gamma_k}{\gamma_0}$. Dividindo as autocovariâncias por γ_0:

$$\frac{\gamma_1}{\gamma_0} = \frac{\theta\sigma^2}{\sigma^2(1+\theta^2)} \implies \rho_1 = \frac{\theta}{1+\theta^2}$$

Como $\rho_0 = 1$ por definição, a solução completa é dada por:

$$\rho_k = \begin{cases} 1, & k = 0 \\ \frac{\theta}{1+\theta^2}, & k = 1 \\ 0, & k > 1 \end{cases}$$

O vetor das primeiras k autocorrelações pode ser escrito como:

$$\boldsymbol{\rho} = \left(\frac{\theta}{1+\theta^2}, 0, \ldots, 0\right).$$

Interpretando de forma semelhante ao processo $AR(1)$, podemos notar que teremos um comportamento oposto para processos $MA(q)$, em que teremos um corte abrupto na autocorrelação a partir do atraso q.

O gráfico das autocorrelações é chamado de correlograma, é o gráfico que mostra o valor da correlação da observação atual com a observação com k atrasos, aqui chamados de *lag*.

Podemos ainda analisar a correlação das observações com um atraso k e apenas essas duas observações, utilizamos então a autocorrelação parcial.

Definição 6.3 *Seja X_t uma série temporal estacionária, a Função de Autocorrelação Parcial é dada por:*

$$\phi_{kk} = \frac{\rho_k - \sum_{j=1}^{k-1} \phi_{k-1,j}\rho_{k-j}}{1 - \sum_{j=1}^{k-1} \phi_{k-1,j}\rho_j}$$

E estimamos como:

$$\hat{\phi}_{kk} = \frac{\hat{\rho}_k - \sum_{j=1}^{k-1} \phi_{k-1,j}\hat{\rho}_{k-j}}{1 - \sum_{j=1}^{k-1} \phi_{k-1,j}\hat{\rho}_j}.$$

Exemplo 6.4 *Seja X_t um processo $AR(1)$. Logo:*

$$X_t = \phi X_{t-1} + \varepsilon_t, \quad |\phi| < 1$$

Para encontrar a PACF, denotada por ϕ_{kk}, utilizamos o algoritmo de Durbin-Levinson. A PACF mede a correlação entre X_t e X_{t-k} após remover a dependência linear das defasagens intermediárias.

Para $k = 1$, a autocorrelação parcial é igual à autocorrelação simples (ρ_1), pois não há termos intermediários para serem removidos:

$$\phi_{11} = \rho_1 = \phi$$

Para $k = 2$, aplicamos a equação de Durbin-Levinson:

$$\phi_{22} = \frac{\rho_2 - \phi_{11}\rho_1}{1 - \phi_{11}\rho_1}$$

Sabendo que para o modelo $AR(1)$ temos $\rho_1 = \phi$ e $\rho_2 = \phi^2$, substituímos os valores na equação:

$$\phi_{22} = \frac{\phi^2 - \phi \cdot \phi}{1 - \phi \cdot \phi} = \frac{0}{1 - \phi^2} = 0$$

Para $k > 1$, como toda a dependência linear da série já foi explicada pelo primeiro lag X_{t-1}, o numerador das equações seguintes sempre será zero. A solução completa é dada por:

$$\phi_{kk} = \begin{cases} \phi, & k = 1 \\ 0, & k > 1 \end{cases}$$

O vetor das primeiras k autocorrelações parciais pode ser escrito como:

$$\boldsymbol{\phi} = (\phi, 0, \ldots, 0)\,.$$

Aqui vemos que a PACF de processos $AR(p)$ se comporta como ACF de processos $MA(q)$, um corte abrupto apos o lag p.

Exemplo 6.5 *Seja X_t um processo $MA(1)$. Logo:*

$$X_t = \varepsilon_t + \theta\varepsilon_{t-1}$$

Para encontrar a PACF, denotada por ϕ_{kk}, utilizamos as autocorrelações ρ_k do modelo e o algoritmo de Durbin-Levinson. Sabemos que para o $MA(1)$, $\rho_1 = \frac{\theta}{1+\theta^2}$ e $\rho_k = 0$ para $k > 1$.

Para $k = 1$, a autocorrelação parcial é igual à autocorrelação simples (ρ_1):

$$\phi_{11} = \rho_1 = \frac{\theta}{1 + \theta^2}$$

Para $k = 2$, aplicamos a equação de Durbin-Levinson:

$$\phi_{22} = \frac{\rho_2 - \phi_{11}\rho_1}{1 - \phi_{11}\rho_1}$$

Substituindo $\rho_2 = 0$ *e os valores de* ρ_1*:*

$$\phi_{22} = \frac{0 - \left(\frac{\theta}{1+\theta^2}\right)^2}{1 - \left(\frac{\theta}{1+\theta^2}\right)^2} = \frac{-\theta^2}{(1+\theta^2)^2 - \theta^2} = \frac{-\theta^2}{1+\theta^2+\theta^4}$$

Ao contrário do processo AR(1), a PACF de um modelo MA(1) não sofre um corte brusco para zero, mas decai assintoticamente. A solução geral é dada por:

$$\phi_{kk} = \frac{-(-\theta)^k(1-\theta^2)}{1-\theta^{2(k+1)}}, \quad k \geq 1$$

O vetor das primeiras k *autocorrelações parciais pode ser escrito como:*

$$\boldsymbol{\phi} = \left(\frac{\theta}{1+\theta^2}, \frac{-\theta^2}{1+\theta^2+\theta^4}, \ldots, \frac{-(-\theta)^k(1-\theta^2)}{1-\theta^{2(k+1)}}\right).$$

Vemos que o comportamento tanto da ACF, quanto da PACF dos processos $AR(p)$ e $MA(q)$ são opostos.

Tabela 6.1: Propriedades teóricas da fac e facp.

Processo	FAC	FACP
AR(p)	decaimento para zero	$0, k > p$
MA(1)	$0, k > 1$	decaimento oscilatório
ARMA(p, q)	decaimento a partir de q	decaimento a partir de p

Capítulo 7

Aplicações práticas

7.1 Removendo tendências

Como falado na seção acima, a estacionariedade é um passo importante para a análise de uma série, então veremos como retirar a tendência de uma série. Para fazermos esse processo pensaremos em uma reta de regressão. Vejamos com o conjunto de dados *Air-Passengers* do `R`. Ja vimos como a série se comporta originalmente na imagem 1.1.

Primeiro devemos analisar a principal, e mais forte, suposição a ser feita sobre uma série, a estacionariedade. Para isso aplicamos o teste de Dickey-Fuller Aumentado, ADF, para avaliar se a série analisada possui raíz unitária, e portanto não é estacionária. Para isso utilizamos a função:

- `adf.test(x,alternative,k)`:
  - `x`: Objeto do tipo `ts` univariada;
  - `alternative`: Hipótese alternativa do teste ADF, o padrão é *'stationary'*, e a outra opção *'explosive'*
  - `k`: Ordem do Lag para realizar o teste, o padrão é: $trunc((length(x)-1)^{(1/3)}))$

Vejamos:

```
library(tseries)
adf.test(sunspot.year)
```

Obtemos o seguinte resultado:

```
    Augmented Dickey-Fuller Test

data:  sunspot.year
Dickey-Fuller = -4.7561, Lag order = 6, p-value = 0.01
alternative hypothesis: stationary
```

O teste utiliza a distribuição *t-Student*. Portanto o p-valor do teste é bem menor que 0.01, mas indica que os dados são estacionários. Portanto, não é necessária a diferenciação, a fim de tornar a série estacionária.

Quando queremos forçar a série a se comportar de forma estacionária podemos aplicar o processo de diferenciação aos dados originais a fim de obtermos uma série em torno de uma média 0. Para isso utilizaremos as funções:

- `ndiffs(x,alpha,...)`:
  - `x`: Objeto do tipo `ts` univariada;
  - `alpha`: Nível de significância do teste de hipótese, assume valores entre 0.01 e 0.1.

- `diff(x,lag,diferences)`:
  - `x`: Objeto do tipo `ts` univariada;
  - `lag`: Qual lag da série utilizar, assume valores inteiros;
  - `diferences`: Ordem da diferença feita na série, assume valores inteiros.

Vejamos:

```
difs<-ndiffs(AP)
plot <- autoplot(diff(AP,difs)) +
  geom_line(linewidth = 0.9, color = 'blue') +
  labs(title = 'Número de passageiros diferenciados',
       subtitle = str_glue('Número de diferenciações:{difs}'))+
  xlab("Tempo") +
  ylab("Passageiros (x1000)") +
  theme_minimal()
show(plot)
```

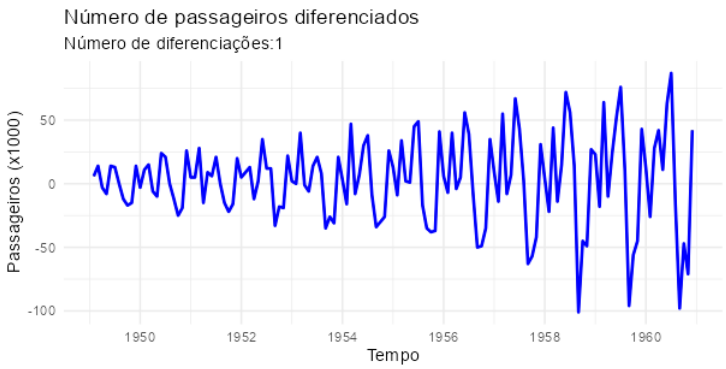


Figura 7.1: Gráfico de *AirPassengers* sem tendência

7.2 Ajuste de modelos

Vejamos exemplos para identificação de um modelo $AR(p)$. Utilizaremos o *dataset sunspot.year* do `R`.

Para fazermos a identificação de modelos utilizaremos das funções de autocorrelação, *acf*, e autocorrelação parcial, *pacf*. Podemos avaliar o comportamento destas funções para a série analisada através do correlograma, o gráfico das autocorrelações, e para isso no `R` temos a função `ggAcf`, do pacote `ggplot2`.

`ggAcf(x, lag.max, type,...)`:

- `x`: Objeto do tipo `ts`;
- `lag.max`: Valor máximo do lag a ser calculado a função;
- `type`: Tipo de função utilizada, `'correlation','partial','covariance'`, sendo que `'correlation'` é a configuração padrão.

Vejamos como aplicar a função, e fazer a identificação e ajuste do modelo. Primeiro fazemos o gráfico inicial para observarmos o comportamento da série.

```
plot<-autoplot(sunspot.year,
         xlab = 'Tempo',
         ylab = 'Número médio',
         size =0.9,
         color = 'blue')+
  labs(title = 'Número médio de manchas solares por ano')+
  theme_minimal()+
show(plot)
```



Figura 7.2: Gráfico da série temporal *sunspot.year*

Uma suposição importante do correlograma é que a série seja estacionária, como já fizemos o teste ADF para este conjunto de dados, não é necessário realizar o teste novamente.

```
acf_SPY <- ggAcf(sunspot.year, lag.max = 26) +
  labs(
    title = "Correlograma"
  )
acf_SPY

pacf_SPY<-ggAcf(sunspot.year),
lag.max = 26,
type = 'partial')+
  labs(
    title = "Correlograma parcial"
  )
pacf_SPY
```

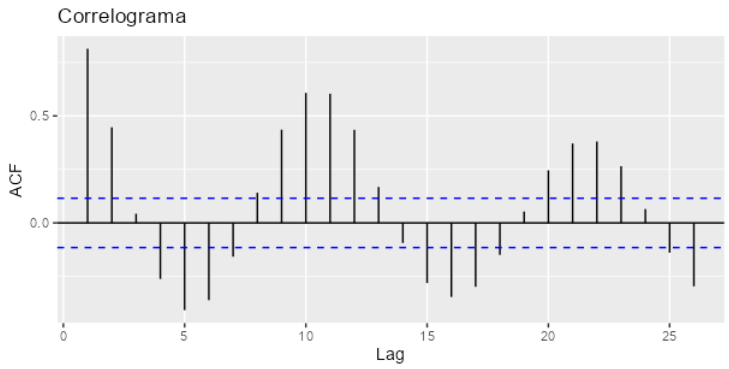


Figura 7.3: Correlograma da série *sunspot.year*

Note que as autocorrelações seguem um formato de onda e decaimento longo, indicando uma possível dependência dos valores passados da série. Logo é razoável supor que ela siga um modelo AR. Vejamos a autocorrelação parcial. Autocorrelação parcial ($pacf$), mede a correlação direta entre valores com atraso, exceto que cada correlação parcial remove qualquer correlação entre observações com um intervalo de tempo menor. Vejamos para a série *sunspot.year*

```
acf_SPY<-Acf(diff(sunspot.year), lag.max = 20, type = 'partial')
plot(acf_SPY)
```

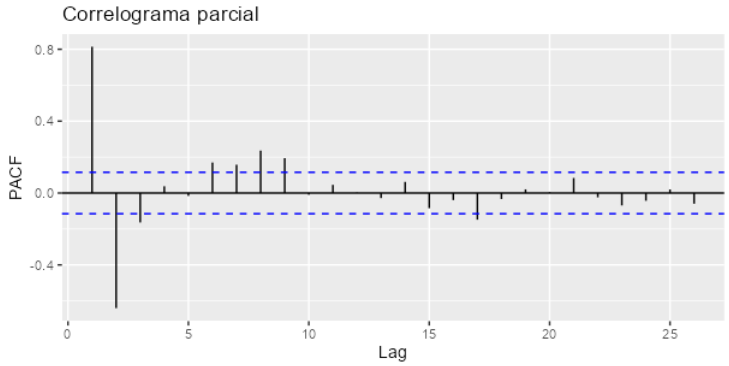


Figura 7.4: Correlograma parcial da série *sunspot.year*

Note que no gráfico acima, temos que as barras no lag 1 até 8 apresentam valores acima da região de confiança e um corte abrupto após para valores posteriores, portanto podemos entender que o valor atual, X_t, tem relação direta aos valores $X_{t-1}, X_{t-2}, \cdots, X_{t-8}$ indicando que a série pode ser melhor explicada pelo modelo: $ARIMA(8, 0, q)$. Como temos uma oscilação muito forte, dado o valor do parâmetro de AR. Vejamos como avaliar o coeficiente de Média Móvel, na tabela 7.2.

Fazemos agora o ajuste do modelo selecionado, com sobreposição do valores previstos pelo modelo e os dados reais para avaliar o encaixe. Para as séries estudadas nessa apostila utilizamos a função `Arima`.

`Arima(x, order, seasonal, include.mean, method, ...)`:

- `x`: Objeto do tipo `ts` ou vetor numérico contendo a série temporal;

Tabela 7.1: Valores de AIC para os modelos ARIMA avaliados

Modelo	AIC	Modelo	AIC	Modelo	AIC
ARIMA(8,0,1)	2411.037	ARIMA(8,0,6)	2400.341	ARIMA(8,0,11)	2408.014
ARIMA(8,0,2)	2411.571	ARIMA(8,0,7)	2403.657	ARIMA(8,0,12)	2402.102
ARIMA(8,0,3)	2414.810	ARIMA(8,0,8)	2414.043	ARIMA(8,0,13)	2411.781
ARIMA(8,0,4)	2411.054	**ARIMA(8,0,9)**	**2399.576**	ARIMA(8,0,14)	2410.929
ARIMA(8,0,5)	2413.040	ARIMA(8,0,10)	2404.133	ARIMA(8,0,15)	2411.430

- `order`: Vetor numérico de três elementos `c(p, d, q)` que especifica a parte não sazonal do modelo (respectivamente: ordem AR, grau de diferenciação e ordem MA);
- `seasonal`: Especificação da parte sazonal do modelo, geralmente passada como uma lista no formato `list(order = c(P, D, Q), period = S)`;
- `include.mean`: Valor lógico (`TRUE` ou `FALSE`) que indica se uma constante (média ou drift) deve ser incluída no modelo estimado;
- `method`: Método de estimação utilizado, podendo ser `'CSS-ML'` (padrão), `'ML'` (Máxima Verossimilhança) ou `'CSS'` (Soma dos Quadrados Condicionais).

```
fit_806<-Arima(sunspot.year, order = c(8,0,6))
rmse_806<-accuracy(fit_806)[1,2]
fit_809<-Arima(sunspot.year, order = c(8,0,9))
rmse_809<-accuracy(fit_809)[1,2]
autoplot(SPY, ylab = "Manchas Solares")+
  autolayer(fit_806$fitted, PI=FALSE, series=forecast:::arima.string(fit_806))+
  autolayer(fit_809$fitted, PI=FALSE, series=forecast:::arima.string(fit_809))+
  labs(title = "Ajuste do modelo de Manchas solares vs Realidade",
       caption = str_glue("RMSE, AIC:\n
       ARIMA(8,0,9):{round(rmse_809,3)}, {round(fit_806$aic,3)}
    \n ARIMA(8,0,6): {round(rmse_806,3)}, {round(fit_809$aic,3)}"))+
  theme_minimal()
```

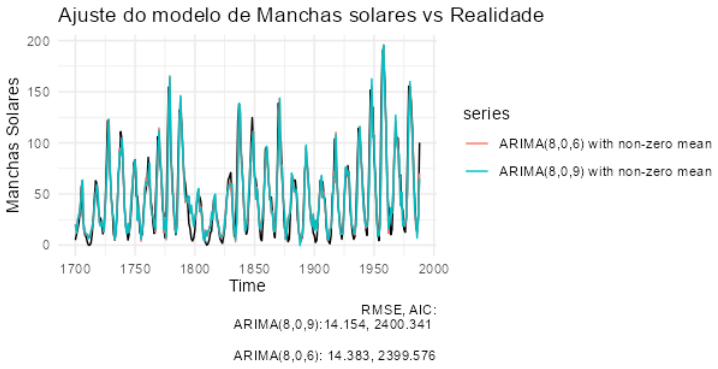


Figura 7.5: Comparação Modelo $ARIMA(8,0,6)$ com $ARIMA(8,0,9)$

Podemos notar que tanto o AIC, quanto $RMSE$ do modelo $ARIMA(8,0,9)$ são menores. Portanto, o melhor modelo que descreve os dados é $ARIMA(8,0,9)$.

7.3 Resíduos

Para realizar todos os passo até aqui, realizamos sempre a suposição que $\varepsilon \sim N(0, \sigma^2)$, e seguem um comportamento de ruido branco. Agora, apos ajuste de um modelo para uma série devemos conferir o comportamento dos resíduos, se confirmam ou não nossa suposição.

Para isso realizaremos alguns procedimentos, todos eles resumidos na função: `checkresiduals`.

- `checkresiduals(x,lag,test,plot)`:
  - `x`: Objeto do tipo `ts`, é assumido ser a série dos resíduos;
  - `lag`: Número de lags a ser usado no teste, padrão é o mínimo entre 10 e $n/5$ para dados não sazonais, e $2m$ e $n/5$ para séries sazonais, sendo que n é o tamanho da série e m período sazonal;
  - `teste`: Teste usado para correlação serial, padrão 'LB', para teste de Ljung-Box.
  - `plot`: Argumento lógico, por padrão o valor é 'TRUE', para gerar os gráficos necessários.

O Teste de Ljung-Box serve para diagnosticar a adequação de um modelo de série temporal, testando se os seus resíduos são independentes e se comportam como um ruído branco. Esse teste segue fielmente a distribuição teórica esperada, evitando a tendência de subestimar evidências de falta de ajuste do modelo em aplicações práticas. A estatística do teste, denotada por $\tilde{Q}$, é calculada a partir das primeiras K autocorrelações dos resíduos $(r_k(\hat{a}))$ e é expressa pela fórmula:

$$\tilde{Q} = n(n+2)\sum_{k=1}^{K} \frac{r_k^2(\hat{a})}{n-k},$$

em que n é o número de observações utilizadas para ajustar o modelo e K é o número de defasagens (lags) testadas. Sob a hipótese nula de que o modelo foi corretamente especificado, $\tilde{Q}$ segue aproximadamente uma distribuição Qui-quadrado (χ^2) com $K-p-q$ graus de liberdade, sendo p e q as ordens dos componentes autorregressivos e de médias móveis do modelo ARIMA, respectivamente.

```
checkresiduals(res,lag = 25)
```

Aqui se faz necessário a adição de um valor específico de `lag`, uma vez que a soma dos parâmetros p e q da um valor muito alto, 17, maior até que o valor mínimo de `lag` do teste.

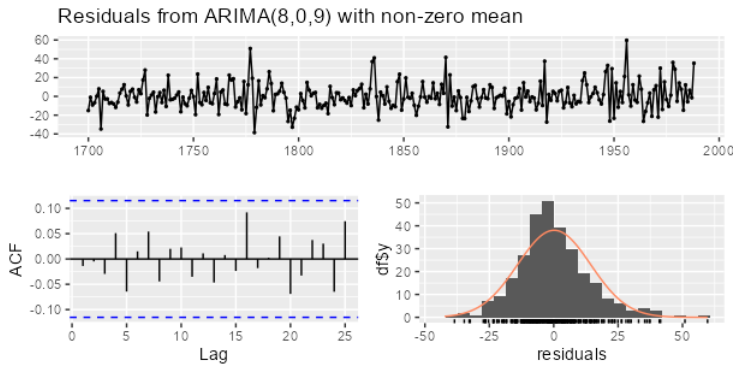


Figura 7.6: Teste dos resíduos do modelo $ARIMA(8, 0, 9)$

E no console recebemos o resultado do teste:

```
    Ljung-Box test

data:  Residuals from ARIMA(8,0,9) with non-zero mean
Q* = 14.379, df = 8, p-value = 0.0724

Model df: 17.   Total lags used: 25
```

Portanto, podemos notar que o ajuste foi bem feito, os resíduos se comportam como ruído branco.

Capítulo 8

Previsão

Chegamos ao objetivo fundamental da maior parte das análises de séries temporais: a previsão de valores futuros. Nos capítulos anteriores, nós detalhamos a natureza das séries temporais, as transformações necessárias para estabilizar a variância, a decomposição de componentes, e os processos de identificação, estimação e ajuste tanto de modelos de Suavização Exponencial quanto da classe de modelos ARIMA.

Neste capítulo, assumimos que o modelo ideal já foi selecionado, seus parâmetros foram estimados adequadamente e os resíduos passaram pelos testes de diagnóstico (ruído branco). O nosso foco agora se volta exclusivamente à mecânica matemática e prática de extrapolar esses modelos para o futuro.

Definiremos o momento atual da série como a origem da previsão, denotado por t. Nosso objetivo é prever a observação Y_{t+h}, onde $h \geq 1$ é o horizonte de previsão (ou *lead time*). Denotaremos a previsão feita no instante t para h passos à frente como $\hat{Y}_t(h)$ ou $\hat{Y}_{t+h|t}$.

8.1 Previsão com Modelos de Suavização Exponencial

Os modelos de Suavização Exponencial geram previsões através de médias ponderadas de observações passadas, onde os pesos decaem exponencialmente à medida que as observações ficam mais antigas. Como nós já ajustamos os parâmetros de suavização (como α, β e γ) e os estados iniciais, a previsão torna-se uma projeção direta dos últimos estados estimados.

8.1.1 Suavização Exponencial Simples (SES)

Para uma série sem tendência ou sazonalidade, a previsão é baseada apenas no nível estimado no tempo t, denotado por L_t. A função de previsão é "plana", o que significa que a previsão para qualquer horizonte futuro é constante:

$$\hat{Y}_t(h) = L_t \tag{8.1}$$

8.1.2 Método Linear de Holt

Quando a série apresenta uma tendência linear e localmente constante, o modelo de Holt incorpora o componente de tendência (ou inclinação), T_t. A previsão para h passos à

frente é uma extrapolação linear simples:

$$\hat{Y}_t(h) = L_t + h \cdot T_t \tag{8.2}$$

Nós podemos observar que, à medida que h aumenta, a previsão cresce ou decresce linearmente sem limites. Na prática, frequentemente aplicamos uma variação com tendência amortecida (*damped trend*), introduzindo um parâmetro ϕ ($0 < \phi < 1$) para evitar projeções irreais a longo prazo:

$$\hat{Y}_t(h) = L_t + \sum_{i=1}^{h} \phi^i T_t \tag{8.3}$$

8.1.3 Método de Holt-Winters (Sazonal)

Para séries com sazonalidade de período m, a função de previsão depende se o modelo ajustado possui sazonalidade aditiva ou multiplicativa.

Para o **modelo aditivo**, a previsão soma o último nível, a tendência extrapolada e o componente sazonal correspondente:

$$\hat{Y}_t(h) = L_t + h \cdot T_t + S_{t+h-m(k+1)} \tag{8.4}$$

onde k é a parte inteira de $(h-1)/m$.

Para o **modelo multiplicativo**, o componente sazonal atua como um fator de escala:

$$\hat{Y}_t(h) = (L_t + h \cdot T_t) \cdot S_{t+h-m(k+1)} \tag{8.5}$$

8.2 Previsão com Modelos ARIMA

Diferente da Suavização Exponencial, a previsão na metodologia Box-Jenkins baseia-se na minimização do erro quadrático médio (MMSE). Para um modelo ARIMA ajustado, a previsão ótima $\hat{Y}_t(h)$ é a esperança matemática condicional da observação futura:

$$\hat{Y}_t(h) = E[Y_{t+h} | Y_t, Y_{t-1}, \dots] \tag{8.6}$$

8.2.1 A Equação de Diferenças

A maneira mais prática de computar essas previsões é usar a forma da equação de diferenças. Para encontrar a previsão, aplicamos a esperança condicional seguindo regras fundamentais:

- $E[Y_{t-j}] = Y_{t-j}$ para $j \geq 0$.
- $E[Y_{t+j}] = \hat{Y}_t(j)$ para $j > 0$.
- $E[Z_{t-j}] = z_{t-j}$ para $j \geq 0$ (resíduos calculados).
- $E[Z_{t+j}] = 0$ para $j > 0$.

8.2.2 Exemplo Numérico: ARIMA(1,1,0)

Considere um modelo ARIMA(1,1,0): $(1 - \phi_1 B)(1 - B)Y_t = Z_t$. Expandindo, temos:

$$Y_t = (1 + \phi_1)Y_{t-1} - \phi_1 Y_{t-2} + Z_t \tag{8.7}$$

Para prever um passo à frente ($h = 1$):

$$\hat{Y}_t(1) = (1 + \phi_1)Y_t - \phi_1 Y_{t-1} \tag{8.8}$$

Para dois passos à frente ($h = 2$):

$$\hat{Y}_t(2) = (1 + \phi_1)\hat{Y}_t(1) - \phi_1 Y_t \tag{8.9}$$

8.2.3 Intervalos de Confiança

A variância do erro de previsão para o horizonte h é dada por:

$$Var[e_t(h)] = \sigma_z^2 \sum_{j=0}^{h-1} \psi_j^2 \tag{8.10}$$

Onde ψ_j são os pesos da representação de média móvel infinita. O intervalo de 95% de confiança é calculado como:

$$\hat{Y}_t(h) \pm 1.96\sqrt{Var[e_t(h)]} \tag{8.11}$$

8.3 Implementação Prática

Nós sempre devemos aplicar a técnica de separar um conjunto de teste (*hold-out sample*) para validar a acurácia das previsões fora da amostra original.

```
library(forecast)

modelo_arima_ajustado <- Arima(serie_treino, order=c(1,1,0))
previsao_arima <- forecast(modelo_arima_ajustado, h=12)

plot(previsao_arima)
lines(serie_teste, col="red")

accuracy(previsao_arima, serie_teste)
```